# Analyseur syntaxique

### Sommaire

- · Problématique
- · Grammaires et arbres de dérivation
- · Mise en œuvre d'un analyseur syntaxique
- · Analyse descendante
- Table d'analyse LL1 · Calcul des premiers
  - · Calcul des suivants
  - Construction de la table LL1
- · Analyseur syntaxique

### Problématique

#### Préambule

Tout langage de programmation possède des règles qui indiquent la structure syntaxique d'un programme bien formé. Par exemple, en Pascal, un programme bien formé est composé de blocs, un bloc est formé d'instructions, une instruction de

La syntaxe d'un langage peut être décrite par une grammaire. Cette grammaire dérits comment les unités lexicales doivent être agencées.

L'analyseur syntaxique reçoit une suite d'unités lexicales de la part de l'analyseur lexical et doit vérifier que cette suite peut être engendrée par la grammaire du langage.

Le problème est donc

• étant donnée une grammaire G• étant donné un mot m (un programme)

 $\implies$  est ce que m appartient au langage généré par G?

Le principe est d'essayer de construire un arbre de dérivation. Il existe deux méthodes pour cette construction : méthode (analyse) descendante et méthode (analyse) ascendante.

### Grammaires et arbres de dérivation

### La grammaire par les exemples

```
Exemples (définitions informelles de grammaires) :
```

dans le langage naturel, une phrase est composée d'un sujet suivi d'un verbe suivi d'un complément (pour simolifier . . .).

Par exemple : L'étudiant subit un cours On dira donc :

phrase = sujet verbe complément

Ensuite, il faut expliquer ce qu'est un sujet, un verbe, un complément. Par exemple :

```
sujet = article adjectif nom
| article nom adjectif
| article nom
article = le | la | un | des| l'
```

adjectif = malin | stupide | coulcur

coulcur = vert | rouge | jaune ainsi de suite . . .

une expression conditionnelle en C est : if (expression) instruction

Par exemple : if (x < 10) a = a + b

Il faut encore définir ce qu'est une expression et ce qu'est une  $instruction \dots$  On distingue les

- symboles terminaux : les lettres du langage (le, la, if ...dans les exemples)
  - symboles non-terminaux : les symboles qu'il faut encore définir (ceux en italique dans les exemples précédents)

# Grammaires et arbres de derivation

Définition 1

Une grammaire est la donnée de  $G = (V_T, V_N, S, P)$  où

 V<sub>T</sub> est un ensemble non vide de symboles terminaux (alphabet terminal) •  $V_N$  est un ensemble de symboles non-terminaux, avec  $V_T \cap V_N = \emptyset$ 

 S est un symbole initial ∈ V<sub>N</sub> appelé axiome • P est un ensemble de règles de productions (règles de réécritures)

# Une règle de production $\alpha \to \beta$ précise que la séquence de symboles $\alpha$ ( $\alpha \in (V_T | V_N)^+$ )

Définition 2

peut être remplacée par la séquence de symboles  $\beta$  ( $\beta \in (V_T \cup V_N)^*$ ).  $\alpha$  est appelée partie gauche de la production, et  $\beta$  partie droite de la production.

Exemple 1

Exemple 2

symboles non-terminaux :  $V_N = \{S\}$ axiome: Srègles de production :

symboles terminaux (alphabet) :  $V_T = \{a, b\}$ 

 $\begin{cases} S \to \varepsilon \\ S \to aSb \end{cases}$  qui se résument en  $S \to \varepsilon \mid aSb$ 

 $G = \langle V_T, V_K, S, P \rangle$  avec

 $V_T = \{$  il, elle, parle, est, devient, court, reste, sympa, vite  $\}$  $V_N = \{ PHRASE, PRONOM, VERBE,$ 

COMPLEMENT, VERBETAT, VERBACTION )

P = { PHRASE → PRONOM VERBE COMPLEMENT

PRONOM → II | elle VERBE → VERBETAT | VERBACTION VERBETAT → est | devient | reste VERBACTION → parle | court

COMPLEMENT → sympa | vite }

#### Arbre de derivation

sur la grammaire de l'exemple 1

#### Définition 1

On appelle dérivation l'application d'une ou plusieurs règles à partir d'un mot de  $(V_T \bigcup V_N)^+$ . On notera  $\to$  une dérivation obtenue par application d'une seule règle de production,  $\stackrel{*}{\to}$  une dérivation obtenue par l'application de n règles de production, où  $n \ge 0$  et  $\stackrel{+}{\to}$  une dérivation obtenue par l'application de n règles de production, où n > 0

## Exemple 1

 $S \rightarrow \varepsilon$   $S \rightarrow aSb$   $aSb \rightarrow aaSbb$   $S \stackrel{*}{\rightarrow} ab$   $S \stackrel{*}{\rightarrow} aaabbb$   $S \stackrel{*}{\rightarrow} aaSbb$ 

#### Exemple 2

sur la grammaire de l'exemple 2 PHRASE  $\rightarrow$  PRONOM VERBE COMPLEMENT  $\stackrel{*}{\rightarrow}$  elle VERBETAT sympa PHRASE  $\stackrel{*}{\rightarrow}$  il parle vite PHRASE  $\stackrel{*}{\rightarrow}$  elle court sympa

# Arbre de dérivation

Définition 2

Etant donnée une grammaire G, on note L(G) le langage généré par G et défini par  $\{w \in (V_T)^* \ \text{tg } S \stackrel{*}{\to} w\}$ (c'est à dire tous les mots composés uniquement de symboles terminaux (de lettres de l'alphabet) que l'on peut

former à partir de S). L'exemple 1 nous donne  $L(G) = \{a^n b^n, n \ge 0\}$ 

Définition 3

On appelle arbre de dérivation (ou arbre syntaxique) tout arbre tel que

Ces deux suites différentes de dérivations donnent le même arbre de dérivation.

- . la racine est l'axiome
- · les feuilles sont des symboles termianux
- · les nocuds sont des symboles non-terminaux • les fils d'un noeud X sont  $\beta_0, \ldots, \beta_n$  si et seulement si  $X \to \beta_0 \ldots \beta_n$  est une production (avec  $\beta_i \in V_{T_i} \setminus V_N$ )

Exemple

pour axiome et pour règles de production

Soit la grammaire ayant S  $P = \begin{cases} S \to aTb \mid c \\ T \to cSS \mid S \end{cases}$ 

 $S \rightarrow aTb \rightarrow acSSb \rightarrow accSb \rightarrow accaTbb \rightarrow accaSbb \rightarrow accacbb$  (dérivations gauches) ou  $S \to aTb \to acSSb \to acSaTbb \to acSaSbb \to acSacbb \to accacbb$  (dérivations droites)

Un arbre de dérivation pour le mos accaebb es


### Arbre de dérivation

#### Définition 3

Une grammaire est dite ambiguë s'il existe un mot de L(G) ayant plusieurs arbres syntaxiques.

Remarque : la grammaire précédente n'est  ${f pas}$  ambiguë,

Cette grammaire est ambiguë car le mot m= if (x>10) if (y<0) a=1 else a=0 possède deux arbres syntaxiques différents :



car il y a deux interprétations syntaxiques possibles :

# mise en œuvre d'un analyseur syntaxique

### Analyseur syntaxique

lexical. Il doit dire si cette suite (ce mot) est syntaxiquement correct, c'est à dire si c'est un mot du langage généré par la grammaire qu'il possède. Il doit donc essayer de construire l'arbre de dérivation de ce mot. S'il y arrive, alors le mot est syntaxiquement correct, sinon il est incorrect.

Il existe deux approches (deux méthodes) pour construire cet arbre de dérivation : que méthode descendante et

L'analyseur syntaxique reçoit une suite d'unités lexicales (de symboles terminaux) de la part de l'analyseur

Il existe deux approches (deux méthodes) pour construire cet arbre de dérivation : une méthode descendante et une méthode ascendante.

### Analyse descendante


### Principe

construire l'arbre de dérivation du haut (la racine, c'est à dire l'axiome de départ) vers le bas (les feuilles, c'est à dire les unités lexicales).

On se retrouve avec



w=jlcb



En lisant le c, on ne sait pas s'il faut prendre la règle  $A \to cd$  ou la règle  $A \to c$ . Pour le savoir, il faut lire aussi la lettre suivante (b). Ou alors, il faut se donner la possibilité de faire des retour en arrière : on essaye la lère règle  $(A \to cd)$ , on aboutit à un échec, alors on retourne en arrière et on essaye la deuxième règle et là ça marche.

### Conclusion

ce qui serait pratique, ça serait d'avoir une table qui nous dit : quand je lis tel caractère et que j'en suis à dériver tel symbole non-terminal, alors j'applique telle règle et je ne me pose pas de questions. Ça existe, et ça s'appelle une **table d'analyse**.

## Analyse descendante

#### Principe

construire l'arbre de dérivation du haut (la racine, c'est à dire l'axiome de départ) vers le bas (les feuilles, c'est à dire les unités lexicales).


On part avec l'arbre contenant le seul sommet SLa lecture de la première lettre du mot (a) nous permet d'avancer la construction



a S b T w= ppcbbadbc

Exemple 2

 $S o aSbT|cT|d \ T o aT|bS|c$  avec le mot w = accbbadbc



On a trouvé un arbre de dérivacion, donc le mut appartient au langage

b.

# Table d'analyse LL1

#### Définition

Pour construire une table d'analyse, on a besoin des ensembles PREMIER et SUIVANT

#### Calcul de Premier

Pour toute chaîne  $\alpha$  composée de symboles terminaux et non-terminaux, on cherche PREMIER( $\alpha$ ) : l'ensemble de tous les **terminaux** (y compris  $\varepsilon$ ) qui peuvent **commencer** une chaîne qui se dérive de  $\alpha$  C'est à dire que l'on cherche toutes les lettres a telles qu'il existe une dérivation  $\alpha \stackrel{*}{\to} a\beta$  ( $\beta$  étant une chaîne quelconque composée de symboles terminaux et non-terminaux). Cas particulier :  $\varepsilon \in \text{PREMIER}(\alpha)$  si et seulement si il existe une dérivation  $\alpha \stackrel{*}{\to} \varepsilon$ 

### Exemple

$$\begin{cases} S \to Ba \\ B \to cP|bP|P|\varepsilon \\ P \to dS \end{cases}$$

$$S \stackrel{*}{\to} a, \text{ donc } a \in \text{PREMIER}(S) \ S \stackrel{*}{\to} cPa, \text{ donc } c \in \text{PREMIER}(S)$$

$$S \stackrel{*}{\to} bPa, \text{ donc } b \in \text{PREMIER}(S) \ S \stackrel{*}{\to} dSa, \text{ donc } d \in \text{PREMIER}(S)$$
If n'y a pas de dérivation  $S \stackrel{*}{\to} \varepsilon$ 
Donc PREMIER $(S) = \{a, b, c, d\}$ 

$$B \stackrel{*}{\to} dS, \text{ donc } d \in \text{PREMIER}(B)$$

$$aB \stackrel{*}{\to} a\alpha, \text{ donc PREMIER}(aB) = \{a\}$$

 $BSb \stackrel{*}{\to} ab$ , donc  $a \in PREMIER(BS)$ 

### Table d'analyse LLI – calcul de Premier –

Algorithme de construction des ensembles Premier(X) pour  $X \in (V_T \cup V_N)$ 1. Si X est un non-terminal et  $X \to Y_1Y_2 \dots Y_n$  est une production de la grammaire (avec  $Y_i$  symbole

- terminal ou non-terminal) alors ajouter les éléments de PREMIER $(Y_1)$  sauf  $\varepsilon$  dans PREMIER(X)
  - s'il existe j ( $j \in \{2, ..., n\}$ ) tel que pour tout i = 1, ..., j-1 on a  $\varepsilon \in PREMIER(Y_i)$ , alors ajouter les éléments de PREMIER( $Y_i$ ) sauf  $\varepsilon$  dans PREMIER(X)
  - alors ajouter les éléments de PREMIER $(Y_i)$  sauf  $\varepsilon$  dans PREMIER(X) si pour tout  $i = 1, \dots, n$   $\varepsilon \in \text{PREMIER}(Y_i)$ ,
- alors a jouter  $\varepsilon$  dans PREMIER(X) 2. Si X est un non-terminal et  $X \to \varepsilon$  est une
- 2. Si X est un non-terminal et  $X \to \varepsilon$  est une production, ajouter  $\varepsilon$  dans PREMIER(X) 3. Si X est un terminal, PREMIER(X) =  $\{X\}$ .
- Recommencer jusqu'à ce qu'on n'ajoute rien de nouveau dans les ensembles PREMIER.

```
Algorithme de construction des ensembles Premier(\alpha) pour \alpha \in (V_T \cup V_N)^*
       On a \alpha = Y_1 Y_2 \dots Y_n avec Y_i \in V_T ou Y_i \in V_N
       si Y est un symbole terminal alors a jouter Y, aux PREMIER(\alpha)
       sinon
              // Y est un symbole non terminal
              ajouter les éléments de PREMIER(Y_i) sauf \varepsilon dans PREMIER(\alpha)
              si \varepsilon \in PREMIER(Y_1) alors
                     // faire la même chose avec Y2
                     si Y<sub>2</sub> est un symbole terminal alors ajouter Y<sub>2</sub> aux PREMIER(a)
                     sinon
                            // Y2 est un symbole non terminal
                            ajouter les éléments de PREMIER(Y_2) sauf \varepsilon dans PREMIER(\alpha)
                            si \varepsilon \in \text{PREMIER}(Y_2) alors
                                   // faire la même chose avec Y2
                                                  // faire la même chose avec Vn
                                                  si Y_n \in V_r alors a jouter Y_n aux PREMIER(\alpha)
                                                  sinon
                                                         // Yn est un symbole non terminal
                                                         ajouter les PREMIER(Y_n) sauf \varepsilon aux PREMIER(\alpha)
                                                         si \varepsilon \in \text{PREMIER}(Y_n) alors
                                                                ajouter s aux PREMIER(a)
                                                         finsi
                                                  fingi
                            firsi
                     finsi
              finsi
```

finsi

### Table d'analyse LL1 - calcul de Premier -

Exemple 1

On considère la grammaire suivante, calculer les premiers de chaque symbole

Non terminal  $\left\{ \begin{array}{l} E \rightarrow TE' \\ E' \rightarrow +TE' | -TE' | \varepsilon \\ T \rightarrow FT' \\ T' \rightarrow *FT' | /FT' | \varepsilon \\ F \rightarrow (E) | \ \mathrm{nb} \end{array} \right.$ 

Exemple 2

On considère la grammaire suivante, calculer les premiers de chaque symbole

Non terminal

$$\begin{cases} S \to ABCe \\ A \to aA|\varepsilon \\ B \to bB|cB|\varepsilon \\ C \to de|da|dA \end{cases}$$

### Table d'analyse LL1 - calcul de Suivant -

#### Définition

Pour tout non-terminal A, on cherche SUIVANT(A): l'ensemble de tous les symboles terminaux  $\alpha$  qui peuvent apparaître immédiatement à droite de A dans une dérivation:  $S \xrightarrow{\pi} \alpha A \alpha \beta$ 

#### Exemple

 $\begin{array}{ll} S \to Sc|Ba & a,b,c,d \in SUIVANT(S) \text{ car il y a les dérivations } S \overset{*}{\to} Sc, S \overset{*}{\to} dSa, S \overset{*}{\to} bdSba \text{ et } S \overset{*}{\to} dSdSaa \\ P \to dS & d \in SUIVANT(B) \text{ car } S \overset{*}{\to} BdSaa \end{array}$ 

#### Algorithme de construction des ensembles Suivant

- Ajouter un marqueur de fin de chaîne (symbole \$ par exemple) à SUIVANT(S) (où S est l'axiome de départ de la grammaire)
- 2. Pour chaque production  $A \rightarrow \alpha B\beta$  où B est un non-terminal, alors
- ajouter le contenu de PREMIER(3) à SUIVANT(B), sauf  $\varepsilon$
- 3. Pour chaque production  $A \to \alpha B$ , alors a jouter SUIVANT(A) à SUIVANT(B)
- 4. Pour chaque production  $A \to \alpha B\beta$  avec  $\varepsilon \in PREMIER(\beta)$ , ajouter SUIVANT(A) à SUIVANT(B)

Recommencer à partir de l'étape 3 jusqu'à ce qu'on n'ajoute rien de nouveau dans les ensembles SUIVANT.

### Table d'analyse LLI – calcul de Sulvant –

Exemple 1

On considère la grammaire suivante, calculer les suivants de chaque symbole Non terminal

$$\begin{cases} E \to TE' \\ E' \to +TE' | -TE' | \epsilon \\ T \to FT' \\ T' \to *FT' | /FT' | \epsilon \\ F \to (E) | \text{ nb} \end{cases}$$

#### Exemple 2

On considère la grammaire suivante, calculer les suivants de chaque symbole Non terminal

```
\left\{ \begin{array}{l} S \rightarrow aSb|cd|SAe \\ A \rightarrow aAdB|e \\ B \rightarrow bb \end{array} \right.
```

# Table d'analyse – Construction de la table LL1 –

### Définition

Une table d'analyse est un tableau M à deux dimensions qui indique pour chaque symbole non-terminal A et chaque symbole terminal a ou symbole S la règle de production à appliquer.

### Algorithme de construction de la table d'analyse

- Pour chaque production  $A \rightarrow \alpha$  faire
  - 1. pour tout  $a \in PREMIER(\alpha)$  (et  $a \neq \varepsilon$ ), rajouter la production  $A \to \alpha$  dans la case M[A, a]2. si  $\varepsilon \in PREMIER(\alpha)$ , alors pour chaque  $b \in SUIVANT(A)$  ajouter  $A \to \alpha$  dans M[A, b]Chaque case M[A, a] vide est une erreur de syntaxe
- Exemple : Compléter la table suivante

### Exemple : Completer la table sulvante

da   +     +   /   (   )   8	$\begin{array}{c ccccccccccccccccccccccccccccccccccc$		$E' \rightarrow +TE'   \sim TE'   \varepsilon$ $T \rightarrow FT'$ $T' \rightarrow \Delta FTU   ET'   \varepsilon$						
	$E \mid E \to TE' \mid$	$\begin{bmatrix} E & E \to TE' \\ E' \\ T & T \to FT' \end{bmatrix}$	$F \to (E)  \text{ nb}$	 	i 1				
	E'   B - 1 B	$\begin{bmatrix} E' \\ T \end{bmatrix}$ $T  o FT'$	F	+		4	 	- /	3

### Analyseur syntaxique

#### Principe

Maintenant qu'on a la table, comment l'utiliser pour déterminer si un mot m donné est tel que  $S \stackrel{*}{\to} m$ ? On utilise une pile.

### Algorithme

données : mot m terminé par S, table d'analyse M initialisation de la pile :

8

et un pointeur ps sur la 1ère lettre de m

repeter

Soit X le symbole en sommet de pile Soit a la lettre pointée par psSi X est un non terminal alors

Si  $M[X,a] = X \rightarrow Y_1 \dots Y_n$  alors

enlever X de la pile mettre  $Y_n$  puis  $Y_{n-1}$  puis ...puis  $Y_1$  dans la pile

émettre en sortie la production  $X \to Y_1 \dots Y_n$ sinon (case vide dans la table)

ERREUR

Sinon

Si X = 3 alors
Si a = \$ alors ACCEPTER
Sinon ERREUR

finsi

Sinon

Si X = a alors enlever X de la pile

avancer ps sinon

ERREUR finsi

finsi finsi

jusqu'à ERREUR ou ACCEPTERS


h

# Analyseur syntaxique Exemple 1

Literapie 1	Pile	Entrée	Sortie
Sur la grammaire E,E',T,T' et F , on cherche à analyser l'instruction m = (7+3)5	\$E	(7+3)5\$	E → TE'
L'arbre syntaxique			
,			
			4
			**

Exemple	Pile	Entrée	Sortie
Sur la grammaire E,E',T,T' et F , on cherche à analyser l'instruction m=3+4*5	\$E	3+4*5\$	E → TE'
_'arbre syntaxique			
34			A
· ·			

- 1	nb	+	-	*	1	(	)	\$
E	E  o TE'					$E \rightarrow TE'$		
E'		$E' \rightarrow +TE'$	$E' \rightarrow -TE'$				$E' \rightarrow \epsilon$	$E' \rightarrow \epsilon$
Г	$T \to FT'$					$T \to FT'$		
T'		$T' \rightarrow \epsilon$	$T' \rightarrow \varepsilon$	$T' \to *FT'$	$T' \rightarrow /FT'$		$T' \rightarrow \varepsilon$	$T' \to \varepsilon$
F	$F \to \mathrm{nb}$					F  o (E)	6 ); 	



#### l'analyse de la phrase 3+4\*5

Pile A	Entrée	Sortie
\$100	3+4*55	(E-TE)
\$ <i>E</i> '+	3+4255	T->FT
\$E' T' F	3+4*5\$	F> nb
\$E' T' pb	3+4*5\$	T'> epsilor
\$E'	+4*5\$	E'> +TE'
SET/	<b>≠</b> 4*5\$	T> FT'
\$E' T' F	4*5\$	F -> nb
\$E' T ŋ8	4*5\$	T' -> * F T'
SE'TF	¥5\$	F->nb
SE' Tob	βS	T -> epsilon
\$E'	\$	E' -> epsilor
\$	\$	ACCEPTER

Arbre de dérivation de la phrase 3+4\*5

