

Les expressions régulières

Définitions

Introduction

Comment décrire un langage ??

Étant donné un mot, appartient il à un langage donné ??

Nous allons parler de la théorie des langages, en particulier nous décrivons les expressions régulières, et par conséquent les langages réguliers

Les langages

Définitions

On appelle **alphabet** un ensemble fini non vide A de symboles (lettres de 1 ou plusieurs caractères).

On appelle **mot** toute séquence finie d'éléments de A .

On note ϵ le **mot vide**.

On note A^* l'ensemble infini contenant tous les mots possibles sur A .

On note A^+ l'ensemble des mots non vides que l'on peut former sur A , c'est à dire $A^+ = A^* - \{\epsilon\}$

On note $|m|$ la longueur du mot m , c'est à dire le nombre de symboles de A composant le mot.

On note A^n l'ensemble des mots de A^* de longueur n . Remarque : $A^* = \bigcup_{n=0}^{\infty} A^n$

Exemples

Soit l'alphabet $A = \{a, b, c\}$. $aaba$, $bbacbb$, c et ϵ sont des mots de A^* , de longueurs respectives 4, 7, 1 et 0.

Soit l'alphabet $A = \{aa, b, c\}$. aba n'est pas un mot de A^* . $baab$, caa , bc , $aaaa$ sont des mots de A^* de longueurs respectives 3, 2, 2 et 2.

Notation

On note \cdot l'opérateur de concaténation de deux mots : si $u = u_1 \dots u_n$ (avec $u_i \in A$) et $v = v_1 \dots v_p$ (avec $v_i \in A$), alors la concaténation de u et v est le mot $u.v = u_1 \dots u_n v_1 \dots v_p$

Remarque : un mot de n lettres est en fait la concaténation de n mots d'une seule lettre.

Les langages

Propriété

$$|u.v| = |u| + |v|$$

$$(u.v).w = u.(v.w) \text{ (associativité)}$$

ε est l'élément neutre pour \cdot : $u.\varepsilon = \varepsilon.u = u$

Remarque : nous écrirons désormais uv pour $u.v$

Définition

On appelle langage sur un alphabet A tout sous-ensemble de A^* .

Exemples

Soit l'alphabet $A = \{a, b, c\}$

Soit L_1 l'ensemble des mots de A^* ayant autant de a que de b . L_1 est le langage infini $\{\varepsilon, c, ccc, \dots, ab, ba, \dots, abccc, acbcc, acbcb, \dots, aabb, abab, abba, baab, \dots, acbcbcbccccc, \dots, bbbcccaacbcabcccaac, \dots\}$

Soit L_2 l'ensemble de tous les mots de A^* ayant exactement 4 a . L_2 est le langage infini $\{aaaa, aaaac, aaaca, \dots, aabaa, \dots, caaaba, \dots, abcabbbaacc, \dots\}$

Operation sur les langages

Opérations sur les langages

union : $L_1 \cup L_2 = \{w \text{ tq } w \in L_1 \text{ ou } w \in L_2\}$

intersection : $L_1 \cap L_2 = \{w \text{ tq } w \in L_1 \text{ et } w \in L_2\}$

concaténation : $L_1 L_2 = \{w = w_1 w_2 \text{ tq } w_1 \in L_1 \text{ et } w_2 \in L_2\}$

puissance : $L^n = \{w = w_1 \dots w_n \text{ tq } w_i \in L \text{ pour tout } i \in \{1, \dots, n\}\}$

étoile : $L^* = \cup_{n \geq 0} L^n$

Les langages réguliers

Problème

étant donné un langage, comment décrire tous les mots acceptables ? Comment décrire un langage ?

Il existe plusieurs types de langage (classification), certains étant plus facile à décrire que d'autres. On s'intéresse ici aux **langages réguliers**.

Définitions

Un langage régulier L sur un alphabet A est défini récursivement de la manière suivante :

- $\{\epsilon\}$ est un langage régulier sur A
- Si a est une lettre de A , $\{a\}$ est un langage régulier sur A
- Si R est un langage régulier sur A , alors R^n et R^* sont des langages réguliers sur A
- Si R_1 et R_2 sont des langages réguliers sur A , alors $R_1 \cup R_2$ et $R_1 R_2$ sont des langages réguliers

Les langages réguliers se décrivent très facilement par une **expression régulière**.

Les langages réguliers

Définitions

Les expressions régulières (E.R.) sur un alphabet A et les langages qu'elles décrivent sont définis récursivement de la manière suivante :

- ε est une E.R. qui décrit le langage $\{\varepsilon\}$
- Si $a \in A$, alors a est une E.R. qui décrit $\{a\}$
- Si r est une E.R. qui décrit le langage R , alors $(r)^*$ est une E.R. décrivant R^*
- Si r est une E.R. qui décrit le langage R , alors $(r)^+$ est une E.R. décrivant R^+
- Si r et s sont des E.R. qui décrivent respectivement les langages R et S , alors $(r)|(s)$ est une E.R. décrivant $R \cup S$
- Si r et s sont des E.R. qui décrivent respectivement les langages R et S , alors $(r)(s)$ est une E.R. décrivant RS
- Il n'y a pas d'autres expressions régulières

Remarques

on conviendra des priorités décroissantes suivantes : $*$, concaténation, $|$ C'est à dire par exemple que $ab^*|c = ((a)((b)^*))|(c)$

En outre, la concaténation est distributive par rapport à $|$: $r(s|t) = rs|rt$ et $(s|t)r = sr|tr$.

Les langages réguliers

Exemples

- $(a|b)^* = (b|a)^*$ dénote l'ensemble de tous les mots formés de a et de b , ou le mot vide.
- $(a)|((b)^*(c)) = a|b^*c$ est soit le mot a , soit les mots formés de 0 ou plusieurs b suivi d'un c . C'est à dire $\{a, c, bc, bbc, bbbc, bbbbc, \dots\}$
- $(a^*|b^*)^* = (a|b)^* = ((\varepsilon|a)b^*)^*$ décrit tous les mots sur $A = \{a, b\}$ ou encore A^*
- $(a|b)^*abb(a|b)^*$ dénote l'ensemble des mots sur $\{a, b\}$ ayant le facteur abb
- $b^*ab^*ab^*ab^*$ dénote l'ensemble des mots sur $\{a, b\}$ ayant exactement 3 a
- $(abbc|baba)^+ao(cc|bb)^* = \{abbcua, \dots, babaabbababaaa, \dots, abbcabbcacccbbbb, \dots\}$

Remarques

$(a|b)^*a(a|b)^*$, qui décrit les mots sur $\{a, b\}$ ayant au moins un a est **ambiguë**. Car, par exemple, le mot $abaab$ "colle" à l'expression régulière de plusieurs manières :

$$abaab = \varepsilon . a . baab \text{ avec } \varepsilon \in (a|b)^*, \text{ et } baab \in (a|b)^*$$

$$abaab = ab . a . ab \text{ avec } ab \in (a|b)^*, \text{ et } ab \in (a|b)^*$$

$$abaab = aba . a . b \text{ avec } aba \in (a|b)^*, \text{ et } b \in (a|b)^*$$

Par contre, l'e.r. $b^*a(a|b)^*$ décrit le même langage et n'est **pas** ambiguë.

$$abaab = \varepsilon . a . baab \text{ avec } \varepsilon \in b^*, \text{ et } baab \in (a|b)^*$$